


Zabójcze zakręty


Krzysztof Kapera

1 Corner B - Wizualizacje


Po wytrenowaniu drivera na jednym eksperymencie, trzeba wyłączyć eksplorację `driver.experiment_rate = 0` i uczenie `driver.step_size = 0`, żeby Q się nie zmieniało w trakcie działania. Wtedy w kolejnym eksperymencie driver będzie jeździł wg nauczonej polityki.



Rysunek 1: track 100



Rysunek 2: track 450




Rysunek 3: track 850


Dobrze jeździ, na początku szeroko, a potem wąsko.

2 Corner C - Studium parametryczne

Corner C jest już dość trudny. Trzeba umieć "spojrzeć poza zakręt", więc wydaje się, że większe n będzie lepsze i niższa α , żeby się stabilniej uczyć.




Rysunek 4: Studium dla 50 epizodów



Rysunek 5: Studium dla 200 epizodów

Intuicja się nie sprawdziła, n akurat wyszło lepsze średnie bądź małe, a α raczej większe, choć dla dużych n lepsze są mniejsze α . Może liczba epizodów jest jeszcze za mała.




Rysunek 6: Studium dla 1000 epizodów


Dla 1000 epizodów już wyszło ciekawie, widać wyraźne optimum dla $n = 4$ i $\alpha = 0.65$. Ogólnie, raczej większe α jest lepsze, a n ma swoje optimum małe, ale nie najmniejsze.

3 Corner D - Wyniki


Elegancko się wytrenował, kary spadają, tor jazdy się poprawia. Na koniec już prawie nie ma czego poprawiać. Znalezione wcześniej parametry sprawdziły się.




Rysunek 7: Kary dla 10000 epizodów




Rysunek 8: Tor jazdy dla 10000 epizodów




Rysunek 9: Kary dla 20000 epizodów



Rysunek 10: Tor jazdy dla 20000 epizodów




Rysunek 11: Kary dla 39900 epizodów




Rysunek 12: Tor jazdy dla 39900 epizodów

4 Pędzenie do przodu


Taką politykę można zaimplementować podobnie do ϵ -greedy, ale zamiast z małym prawdopodobieństwem wybierać losową akcję, z małym (lub średnim) prawdopodobieństwem wybieramy akcję, która przyspiesza.




Rysunek 13: Kary dla 1000 epizodów




Rysunek 14: Tor jazdy dla 1000 epizodów




Rysunek 15: Kary dla 5000 epizodów



Rysunek 16: Tor jazdy dla 5000 epizodów



Rysunek 17: Kary dla 9950 epizodów




Rysunek 18: Tor jazdy dla 9950 epizodów


Ogólnie to się wyuczył, ale często bez potrzeby wjeżdża w ściany. Widać duże spiki na wykresie kar, to są te momenty, kiedy agent wypada z toru i jest cofnięty na start.

5 Bez Importance Sampling


Wystarczy ustawić ρ na stałe na 1. Patrzymy na n kroków do przodu, a przy takiej polityce znajdzie się w nich dużo przyspieszeń, które będą psuły tor jazdy. Wobec tego, dobre akcje i tak będą karane. Bez Importance Sampling agent nie będzie odrzucał błędnych akcji, czyli będzie się uczył na ich podstawie, zamiast na podstawie dobrych akcji. W efekcie trening nie będzie w ogóle skuteczny.




Rysunek 19: Kary dla 950 epizodów




Rysunek 20: Tor jazdy dla 950 epizodów




Rysunek 21: Kary dla 4950 epizodów



Rysunek 22: Tor jazdy dla 4950 epizodów



Rysunek 23: Kary dla 8800 epizodów



Rysunek 24: Tor jazdy dla 8800 epizodów

I faktycznie, zwykle jest bardzo źle. Kary są ciągle wysokie. Rzadko, ale się zdarza, że przejedzie dobrym torem jazdy, ale to raczej przypadek. Ustawiłem 15% szansy na przyspieszenie, może to za mało, żeby za każdym razem się psuło.