

Plan Prezentacji

Wstęp - problem

- deep information retrieval - wyszukiwanie złożonych informacji w internecie i łączenie ich w satysfakcjonującą, pozbawioną sprzeczności i halucynacji odpowiedź
- obecne rozwiązania: wykorzystanie LLM komercyjnych (Gemini, ChatGPT), architektury wielomodalne (łączenie LLM)
- problem - wymagają dostępu do własności intelektualnej firmy i kosztują pieniądze

Propozycja rozwiązania

- **ASearcher:**
 - Czyste RL end to end → nie wykorzystuje wielkich modeli, działa jedynie za pomocą uczenia ze wzmocnieniem
 - System asynchroniczny → RL jest bardzo powolne. W modelu zaproponowanym przez autorów zbieranie danych z internetu i trenowanie modelu odbywa się niezależnie i równolegle
 - Synteza danych → aturoski proces produkcji pytań treningowych, tworzenie trudnych pytań z łatwych
 - Dostęp do dwóch narzędzi - wyszukiwarki i przeglądarki
 - Twórcy nie projektowali od zera nowej sieci neuronowej. Wykorzystali QwQ-32B, czyli istniejący, otwarty duży model językowy (LLM) posiadający 32 miliardy parametrów. Następnie poddali go procesowi asynchronicznego uczenia ze wzmocnieniem (RL).

Dane treningowe - jak je tworzymy?

- wygenerowanie 25,6 tysiąca trudnych pytań, wymagających użycia narzędzi w wielu turach

Wykres 1)

- Mamy pytanie i fakty, które wspierają pytanie.
- Wybieramy albo injection (zastąpienie jednego słowa czymś opisującym to słowo np zamiast pletwal błękitny - największy ssak świata)
- albo fuzz - rozmycie sensu np zamiast rok 2014 - używamy wczesne lata 2010.
- Później następuje weryfikacja czy to pytanie ma tę samą odpowiedź co oryginalne, czy ma sens i czy przez fuzz nie sprawiliśmy, że to pytanie ma więcej niż 1 odpowiedź.

System korzysta z dwóch głównych, osobnych źródeł danych. Pierwszym z nich jest 16 tysięcy przefiltrowanych pytań z otwartych zbiorów (HotpotQA itp.). Drugim źródłem jest 25,6 tysiąca pytań syntetycznych, utworzonych za pomocą modułu *Data Synthesis Agent* (akcje Injection i Fuzz) na bazie innej puli początkowej (ponad 14 tysięcy tzw. *seed QA*)

Proces uczenia

Wykres 2)

- najpierw mamy jakiś stan (w stym historię)

- agent zastanawia się co zrobić i sam formułuje sobie polecenia
- wybiera jedną z trzech opcji:
 - wyszukiwanie czegoś
 - wyświetlenie strony internetowej
 - zapisanie odpowiedzi
- może to robić max 128 razy

Asynchroniczna optymalizacja zasobów

Wykres 3)

- większość prób rozwiązania zadania kończy się dość szybko i zużywa mało tokenów, ale mamy długi ogon outlierów, zużywających mega dużo tokenów
- w standardowym RL zadania grupuje się w batche, jeśli w batchu znajduje się jedno mega długie zadanie, cały system czeka na jego rozwiązanie, co wydłuża probes

Wykres 4):

- rozdzielenie procesu generowania danych z internetu od treningu modelu

Szczegóły implementacji

- Opis środowiska poprzez MDP (Procesy Markova) - Określa on zbiór stanów S (historia operacji, wyniki pobrane z przeglądarki), zbiór dostępnych akcji A (wywołanie wyszukiwarki lub generowanie tekstu) oraz funkcję nagrody R , która wyznacza ostateczny cel. Cel systemu - zadaniem algorytmu jest maksymalizacja nagród.
- **GRPO (Group Relative Policy Optimization)** - algorytm optymalizacji używany do uczenia ze wzmocnieniem. Zamiast oceniać każdą próbę rozwiązania problemu osobno, GRPO wymaga wygenerowania całej grupy G różnych trajektorii dla jednego pytania. Algorytm zestawia wyniki wszystkich prób w tej grupie i wylicza wartość przewagi, promując te sekwencje akcji, które uzyskały wynik powyżej średniej.
- Ewaluacja przez LLM-as-judge, brak oceny formatowania

Eksperymenty i weryfikacja wyników

- benchmarki:
 - **GAIA** (103)
 - **Frames** (824)
 - **xBench-DeepSearch**: 100 wymagających pytań po chińsku
 - **HLE** (500, bardzo trudne)

Przykład pytania:

„Ile złotych medali zdobyły Chiny na Igrzyskach Olimpijskich w Londynie w 2012 roku?” w rzeczywistości wymaga zawilego rozumowania. W tamtym czasie Chinom przypisano 38 złotych medali, ale dekadę później dwie dyskwalifikacje za doping w chodzie sportowym kobiet doprowadziły do przyznania Chinom dodatkowego złotego medalu, podnosząc łączną liczbę do 39.

Zero-shot Transfer:

W fazie ewaluacji badacze zmodyfikowali architekturę poprzez włączenie potężnego modelu zewnętrznego (DeepSeek-V3), który służył do podsumowania tekstu na stronie internetowej.

Oprócz samego podsumowywania stron, DeepSeek-V3 posłużył do agregacji wyników. System generował 16 niezależnych ścieżek rozwiązania tego samego problemu (technika *Test-time Scaling*), a zewnętrzny model wyciągał z nich ostateczny wniosek.

Porównanie z konkurencją:

- **Rozwiązania komercyjne:** OpenAI DeepResearch, Kimi-Researcher.
- **Duże modele ogólne (z narzędziami):** Qwen3-30B, Qwen3-235B, OpenAI-o3, DeepSeek-R1, Claude-4-Sonnet.
- **Inne systemy open-source (klasa 32B):** Search-o1, Search-R1-32B, WebThinker-QwQ, AFM-RL-32B (wieloagentowy), MiroThinker (więcej narzędzi: audio/video) i inne.

Wynik to procent udanych odpowiedzi przy pojedynczej próbie (każde pytanie zadajemy raz)

Wykres 5) i 6)

- Z rozwiązań niekomercyjnych ASearcher wykazuje bardzo wysoką skuteczność
- Po dodaniu modelu podsumowującego (DeepSeek - jedynie podsumowuje strony internetowe) system ma wyniki porównywalne z komercyjnymi LLMami

Case Study

Search-R1-32B (Jin i in., 2025) VS ASearcher

Wykres 6)

ASearcher rozбивa pytanie na mniejsze pytania, szuka po kolei, podsumowuje powiązane informacje ze strony internetowej i analizuje odpowiedzi po czym poświęca tury na weryfikację wniosków przed odpowiedzią

Zjawiska wyłaniające się

Emergent behaviours - umiejętności lub sposoby działania, których wprost go nie nauczono ale wynikają z procesu treningu

Wykres 7)

Wykresy pokazują zmianę częstotliwości używania konkretnych słów przez agenta w miarę trwania procesu treningowego do reasoningu (swoich wewnętrznych procesów)

Po lewej stronie - agent w trakcie treningu coraz częściej myśli w sposób strukturalny, analizuje swoje postępy ale też wstrzymuje się z decyzją do czasu uzyskania pełniejszych informacji

Po prawej - odwoływanie do źródeł zewnętrznych - argumentuje swoje decyzje konkretnymi dokumentami i wspomina o wcześniejszych wynikach

Badania ablacyjne

Badania ablacyjne - metoda testowania w której stopniowo wyłącza się lub zmienia pojedyncze elementy systemu, aby sprawdzić, jaki mają one wpływ na całość.

- **Cel badań ablacyjnych:** Weryfikacja wpływu trzech głównych zmiennych (limit tur, etapy nauki, zestaw danych) na ostateczne wyniki osiągnięte przez model.
- **Wpływ limitu iteracji (Q1):** Ograniczenie algorytmu do 10 tur w fazie treningu drastycznie obniża jego skuteczność (spadek wyniku z 58.7 do 49.2 w teście GAIA).
- **Przestrzeń eksploracji:** Utrzymanie wysokiego limitu tur jest fundamentalne, ponieważ zapewnia systemowi odpowiednią ilość czasu na budowanie i samodzielne odkrywanie złożonych strategii.

- **Dwuetaповy proces uczenia (Q2):** Skupienie się w drugiej fazie treningu na skomplikowanych zapytaniach (wymagających użycia narzędzi co najmniej pięć razy) daje wyraźnie lepsze rezultaty niż nauka na prostym, jednorodnym zbiorze.
- **Jakość własnych danych treningowych (Q3):** Zastąpienie autorskiego zbioru danych zestawem z konkurencyjnego badania (AFM) znacząco pogarsza rezultaty, co udowadnia wyższość zastosowanej w pracy metody generowania trudnych pytań.

Wnioski

Stworzono model RL, który może zastępować komercyjne LLM w odpowiedzi na trudne i złożone pytania, system treningowy jest asynchroniczny co przyspiesza naukę. Opracowana metoda syntezy danych treningowych znacząco poprawiła rezultaty względem innych treningów.