Uczenie ze Wzmocnieniem

[Reinforcement Learning]

Zaliczenie

JAK TO SIĘ ZALICZA?

- Laboratoria
  - Punkty za aktywności
  - Punktów nieco więcej niż 100%
  - Brak aktywności obowiązkowych
  - Standardowa skala oceniania
- Egzamin
  - Pisemny na żywo w początkowych terminach, ustny na żywo w późniejszych
  - Będzie egzamin zerowy – warunek dopuszczenia: zaliczenie laboratoriów przed ostatnim wykładem
- Ocena końcowa
  - Średnia z oceny z laboratorium i oceny z egzaminu, zaokrąglana na korzyść studenta

Bibliografia (dla części pierwszej)

- Sutton, Richard S., and Andrew G. Barto. *Reinforcement learning: An introduction*. MIT press, 2020.
- …z częścią drugą będzie trochę trudniej…

Bibliografia (d szej)

- Sutton, Richar
  Reinforcem
  press, 2

2024 ACM A.M. Tu
Laureates

ACM A.M. Turing Award Honors Two Researchers Who Led the Development of Cornerstone AI Technology

Andrew Barto and Richard Sutton Recognized as Pioneers of Reinforcement Learning

ACM has named Andrew G. Barto and Richard S. Sutton as the recipients of the 2024 ACM A.M. Turing Award for developing the conceptual and algorithmic foundations of reinforcement learning. In a series of papers beginning in the 1980s, Barto and Sutton introduced the main ideas, constructed the mathematical foundations, and developed important algorithms for reinforcement learning—one of the most important approaches for creating intelligent systems.

Barto is Professor Emeritus of Information and Computer Sciences at the University of Massachusetts, Amherst. Sutton is a Professor of Computer Science at the University of Alberta, a Research Scientist at Keen Technologies, and a Fellow at Amii (Alberta Machine Intelligence Institute).

The ACM A.M. Turing Award, often referred to as the "Nobel Prize in Computing," carries a $1 million prize with financial support provided by Google, Inc. The award is named for Alan M. Turing, the British mathematician who articulated the mathematical foundations of computing.

What is Reinforcement Learning?

The field of artificial intelligence (AI) is generally concerned with constructing agents—that is, entities that perceive and act. More intelligent agents are those that choose better courses of action. Therefore, the notion that some courses of action are better than others is central to AI. Reward—a term borrowed from psychology and neuroscience—denotes a signal provided to an agent related to the quality of its behavior. Reinforcement learning (RL) is the process of learning to behave more successfully given this signal.

The idea of learning from reward has been familiar to animal trainers for thousands of years. Later, Alan Turing's 1950 paper "Computing Machinery and Intelligence," addressed the question "*Can machines think?*" and proposed an approach to machine learning based on rewards and punishments.

While Turing reported having conducted some initial experiments with this approach and Arthur Samuel developed a checker-playing program in the late 1950s that learned from self-play, little further progress occurred in this vein of AI in the following decades. In the early 1980s, motivated by observations from psychology, Barto and his PhD student Sutton began to formulate reinforcement learning as a general problem framework.

They drew on the mathematical foundation provided by Markov decision processes (MDPs), wherein an agent makes decisions in a stochastic (randomly determined) environment, receiving a reward signal after each transition and aiming to maximize its long-term cumulative reward. Whereas standard MDP theory assumes that everything about the MDP is known to the agent, the RL framework allows for the environment and the rewards to be unknown. The minimal information requirements of RL, combined with the generality of the MDP framework, allows RL algorithms to be applied to a vast range of problems, as explained further below.

Barto and Sutton, jointly and with others, developed many of the basic algorithmic approaches for RL. These include their foremost contribution, temporal difference learning, which made an important advance in solving reward prediction problems, as well as policy-gradient methods and the use of neural networks as a tool to represent learned functions. They also proposed agent designs that combined learning and planning, demonstrating the value of acquiring knowledge of the environment as a basis for planning.

Perhaps equally influential was their textbook, *Reinforcement Learning: An Introduction* (1998), which is still the standard reference in the field and has been cited over 75,000 times. It allowed thousands of researchers to understand and contribute to this emerging field and continues to inspire much significant activity in computer science today.

nd Sutton's algorithms were developed decades ago, major advances in the practical me about in the past fifteen years by merging RL with deep learning algorithms g Awardees Bengio, Hinton, and LeCun). This led to the technique of deep

was the victory by the AlphaGo computer program over the best other major achievement recently has been the development of guage model (LLM) trained in two phases, the second of learning from human feedback (RLHF), to capture human

Andrew Barto is Professor Emeritus, Department of Information and Computer Sciences, University of Massachusetts, Amherst. He began his career at UMass Amherst as a postdoctoral Research Associate in 1977, and has subsequently held various positions including Associate Professor, Professor, and Department Chair. Barto received a BS degree in Mathematics (with distinction) from the University of Michigan, where he also earned his MS and PhD degrees in Computer and Communication Sciences.

Barto's honors include the UMass Neurosciences Lifetime Achievement Award, the IJCAI Award for Research Excellence, and the IEEE Neural Network Society Pioneer Award. He is a Fellow of the Institute of Electrical and Electronics Engineers (IEEE), and a Fellow of the American Association for the Advancement of Science (AAAS).

Richard Sutton is a Professor in Computing Science at the University of Alberta, a Research

Reinforcem
cement
G. Barto

Definicja?

- metody obliczeniowe służące zrozumieniu i automatyzacji uczenia nastawionego na osiąganie celów i podejmowanie decyzji
- centralny paradygmat: uczenie poprzez bezpośrednią interakcję ze środowiskiem, bez polegania na zewnętrznym nadzorze
- konieczność ciągłych kompromisów pomiędzy eksploracją a eksploatacją
- przykłady?
- co zostało pominięte?
  - problemy związane z postrzeganiem i reprezentacją stanu
  - uczenie bez opierania się o interakcje (np. metody ewolucyjne)

Kluczowe elementy systemu uczącego się

- **agent** [agent]
  - postrzega w jakimś zakresie stan środowiska
  - wykonuje akcje, które na niego wpływają
  - ma cele związane z osiąganiem konkretnych stanów
- **środowisko** [environment]
  - rzeczywistość poza agentem
- **polityka** [policy]
  - definiuje sposób w jaki zachowuje się agent
  - (zazwyczaj) mapuje postrzegane stany na akcje do wykonania w ich następstwie
- **sygnał nagrody** [reward signal]
  - zwrotna informacja środowiska o pożądanym (lub nie) natychmiastowym skutku podjętej akcji
- **funkcja wartościująca** [value function]
  - informacja o długofalowych konsekwencjach znalezienia się w danej sytuacji
  - (zazwyczaj) wartość oczekiwana sumy wszystkich przyszłych nagród
- (opcjonalnie) **model środowiska** [model]

Problem Wielorękich Bandytów

[Multi-armed Bandits Problem]

K-ręki bandyta

- w każdym kroku czasowym należy wybrać jedną z *k* akcji („dźwigni”)
- po dokonaniu wyboru przyznawana jest nagroda losowana w oparciu o stacjonarny rozkład prawdopodobieństwa związany z wybraną akcją
- celem jest maksymalizacja wartości oczekiwanej nagród otrzymanych po pewnej przyjętej liczbie kroków (np. 1000)

K-ręki bandyta

- funkcja wartościująca akcje (action value)

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

- optymalna polityka jest trywialna, jeżeli $q_*(a)$ jest znana
- w praktyce znamy tylko pewną jej estymatę $Q_t(a)$

K-ręki bandyta

- **zachłanny** wybór akcji o największym Q_t to **eksploatacja** aktualnej wiedzy
- wybór innej akcji to **eksploracja**
- pierwsze zapewnia największą nagrodę krótkoterminowo, drugie daje potencjał na długoterminową poprawę

- oba podejścia są w konflikcie!
- jak znaleźć właściwy balans?

Metody oparte o wartościowanie akcji

- estymowanie wartości metodą **średniej z próbek** [sample-average]

$$Q_t(a) \doteq \frac{\text{sum of rewards when } a \text{ taken prior to } t}{\text{number of times } a \text{ taken prior to } t} = \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{1}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{1}_{A_i=a}}$$

- zachłanny wybór akcji

$$A_t \doteq \underset{a}{\operatorname{argmax}}\, Q_t(a)$$

- by zapewnić szansę na eksplorację zamieniamy go na wariant **ε-zachłanny** [ε-greedy] (z małym prawdopodobieństwem ε akcja wybierana jest losowo)

- jaki wybrana wartość ε wpływa na uzyskiwane wyniki?
- wyniki w oparciu o testowy benchmark składający się z 2000 problemów

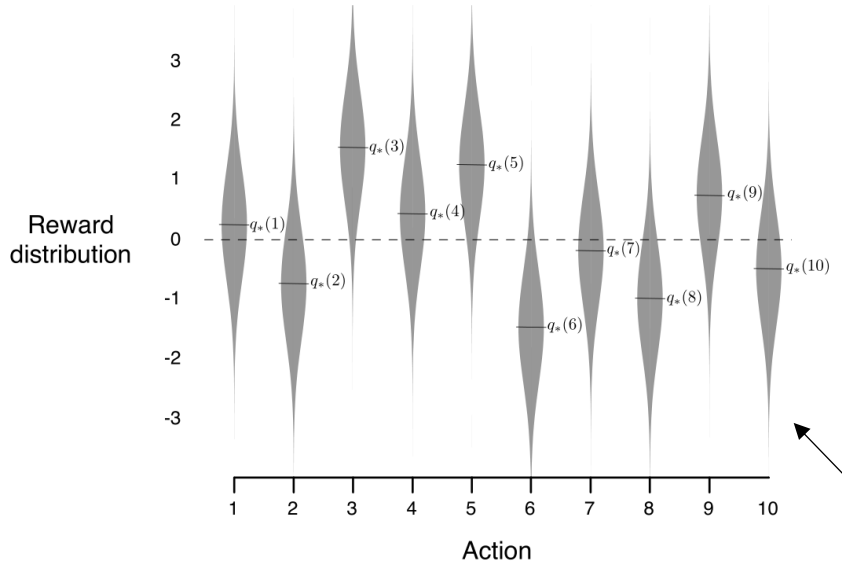

przykładowy problem

Wpływ współczynnika ε

(mechanizm czasem pojawiający się pod nazwą „dithering” – „roztrząsanie”)

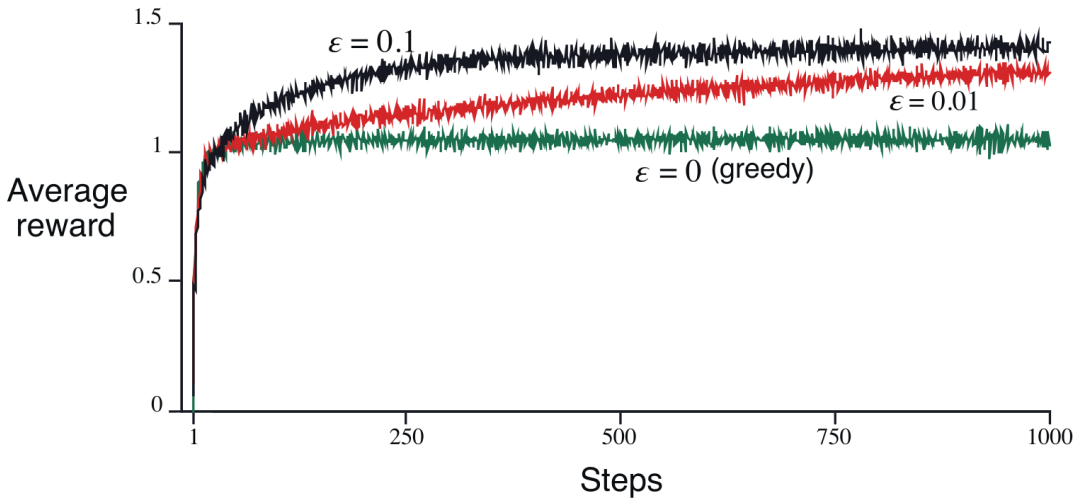

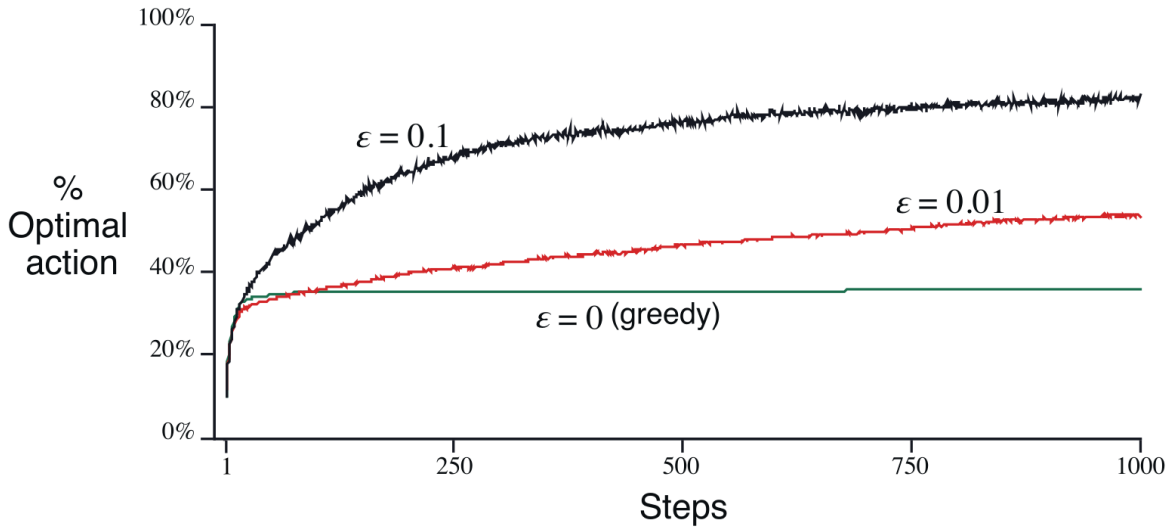

Praktyczna implementacja

$$
\begin{aligned}
Q_{n+1} &= \frac{1}{n}\sum_{i=1}^{n} R_i \\
&= \frac{1}{n}\left(R_n + \sum_{i=1}^{n-1} R_i\right) \\
&= \frac{1}{n}\left(R_n + (n-1)\frac{1}{n-1}\sum_{i=1}^{n-1} R_i\right) \\
&= \frac{1}{n}\Big(R_n + (n-1)Q_n\Big) \\
&= \frac{1}{n}\Big(R_n + nQ_n - Q_n\Big) \\
&= Q_n + \frac{1}{n}\Big[R_n - Q_n\Big],
\end{aligned}
$$

A simple bandit algorithm

Initialize, for $a = 1$ to k:
$Q(a) \leftarrow 0$
$N(a) \leftarrow 0$

Loop forever:
$A \leftarrow \begin{cases} \arg\max_a Q(a) & \text{with probability } 1-\varepsilon \quad \text{(breaking ties randomly)} \\ \text{a random action} & \text{with probability } \varepsilon \end{cases}$
$R \leftarrow bandit(A)$
$N(A) \leftarrow N(A) + 1$
$Q(A) \leftarrow Q(A) + \frac{1}{N(A)}\big[R - Q(A)\big]$

$$NewEstimate \leftarrow OldEstimate \; + \; StepSize \Big[Target - OldEstimate\Big]$$

Średnia wykładniczo ważona aktualnością

- [exponential recency-weighted average]
- przydatna przy problemach niestacjonarnych
- potencjalnie α może zmieniać się z każdym kolejnym krokiem lub kolejnym wykonaniem akcji a
  - $\alpha_n(a) = \frac{1}{n}$ jest równoważne średniej z próbek
  - warunki na zbieżność:

$$\sum_{n=1}^{\infty} \alpha_n(a) = \infty \qquad \sum_{n=1}^{\infty} \alpha_n^2(a) < \infty$$

  - nie zbiega się dla $\alpha_n(a) = \alpha$!

$$\begin{aligned}
Q_{n+1} &= Q_n + \alpha\Big[R_n - Q_n\Big] \\
&= \alpha R_n + (1-\alpha)Q_n \\
&= \alpha R_n + (1-\alpha)\left[\alpha R_{n-1} + (1-\alpha)Q_{n-1}\right] \\
&= \alpha R_n + (1-\alpha)\alpha R_{n-1} + (1-\alpha)^2 Q_{n-1} \\
&= \alpha R_n + (1-\alpha)\alpha R_{n-1} + (1-\alpha)^2 \alpha R_{n-2} + \\
&\qquad \cdots + (1-\alpha)^{n-1}\alpha R_1 + (1-\alpha)^n Q_1 \\
&= (1-\alpha)^n Q_1 + \sum_{i=1}^{n} \alpha(1-\alpha)^{n-i} R_i.
\end{aligned}$$

Optymistyczne startowe estymaty wartości

- startowe wartości $Q_1(a)$ wpływają na finalnie uzyskiwane estymaty (powodują obciążenie [**bias**])
- w przypadku średniej z próbek bias znika gdy wszystkie akcje były wybrane przynajmniej raz
- wartości Q_1 są parametrami, które musi wybrać inżynier
- możemy to wykorzystać, by zachęcać do początkowej eksploracji!

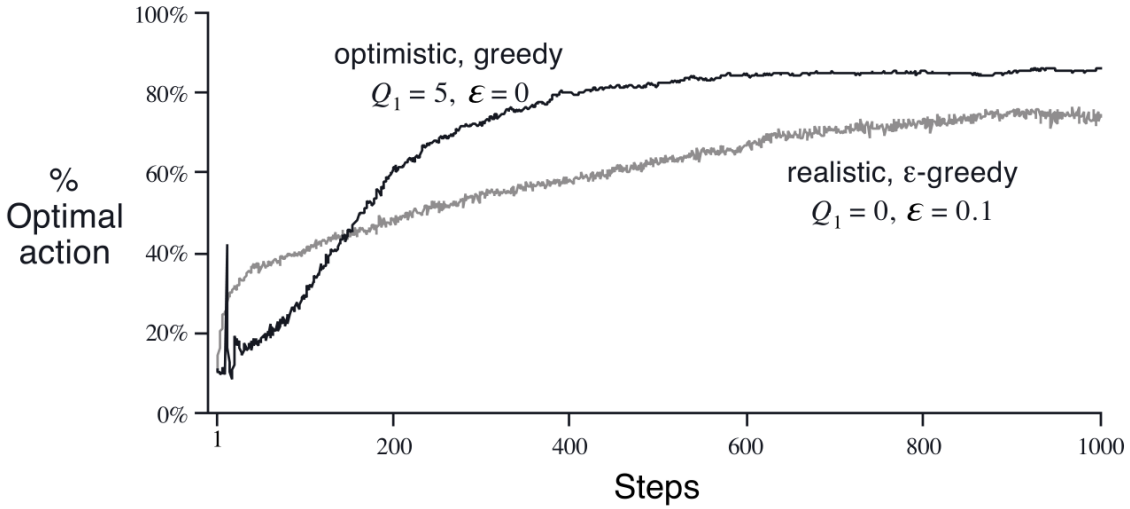

- wykres powyżej sporządzono dla α=0.1 i uśredniono dla 2000 losowych zadań
- z czego mogą wynikać oscylacje w jego początkowej fazie?

Selekcja w oparciu o górną granicę ufności

- w selekcji typu UCB (**Upper Confidence Bounds**) wybieramy zachłannie w oparciu o aktualną estymatę wartości danej akcji oraz górną granicę ufności powiązaną z tą estymatą

estymata na bazie średniej z t próbek

$$Q(a) \leq \hat{Q}_t(a) + \hat{U}_t(a)$$

$$a_t^{UCB} = argmax_{a \in \mathcal{A}} \hat{Q}_t(a) + \hat{U}_t(a)$$

- pozostaje więc pytanie – jak z kolei estymować tą granicę?
- skorzystamy z nierówności Hoefdinga

$$\mathbb{P}[\mathbb{E}[X] > \overline{X}_t + u] \leq e^{-2tu^2}$$

- dla naszego przypadku będzie ona wyglądać następująco

$$\mathbb{P}[Q(a) > \hat{Q}_t(a) + U_t(a)] \leq e^{-2tU_t(a)^2}$$

prawdopodobieństwo, że nasza estymata (wraz z granicą ufności) jest za niska

- chcemy, by granica „działała”, a więc prawdopodobieństwo lewej nierówności było jak najniższe; przyjmijmy, że wystarczy nam pewne małe p

$$e^{-2tU_t(a)^2} = p \qquad U_t(a) = \sqrt{\frac{-\log p}{2N_t(a)}}$$

t zostało zamienione na konkretny licznik wystąpień danej akcji: $N_t(a)$

- ile powinno wynosić p? jedną z najpopularniejszych heurez jest uznanie, że powinno maleć z czasem, np. $p = t^{-4}$
- uzyskujemy wtedy algorytm UCB1

$$A_t \doteq \underset{a}{\operatorname{argmax}} \left[Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right]$$

Interludium – nierówność Hoeffdinga

- mamy **nierówność Markova** (dla nieujemnych zmiennych losowych)

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

(szkic dowodziku dla nieufnych)

$$\mathbb{E}[X] = \sum_{x<a} x\mathbb{P}(X = x) + \sum_{x \geq a} x\mathbb{P}(X = x).$$

pomijamy lewą połowę, z prawej bierzemy x = a

$$\mathbb{E}[X] \geq \sum_{x \geq a} a\mathbb{P}(X = x)$$

wyciągamy a przed sumę, zwijamy ją do jednego wyrażenia

$$\mathbb{E}[X] \geq a\mathbb{P}(X \geq a)$$

- mamy też wersję uogólnioną dla dowolnej niemalejącej nieujemnej funkcji

$$\mathrm{P}(X \geq a) \leq \frac{\mathrm{E}(\varphi(X))}{\varphi(a)}$$

- a nam za chwilę przyda się taka postać

$$\mathbb{P}(Y \geq c) \leq \frac{\mathbb{E}[e^{sY}]}{e^{sc}}$$

Interludium – nierówność Hoeffdinga

$$\mathbb{P}(Y \geq c) \leq \frac{\mathbb{E}[e^{sY}]}{e^{sc}}$$

to nasze próbki – znane rezultaty akcji

$$Y = \sum_{i=1}^{t}(X_i - \mathbb{E}[X])$$

po podstawieniu i przyjęciu c = tu

$$\mathbb{P}\left(\sum_{i=1}^{t}(X_i - \mathbb{E}[X]) \geq tu\right) \leq \frac{\mathbb{E}\left[e^{s\sum_{i=1}^{t}(X_i - \mathbb{E}[X])}\right]}{e^{stu}}$$

próbki były niezależne, wiec możemy rozbić sumę na elementy

$$\mathbb{E}\left[e^{s\sum_{i=1}^{t}(X_i - \mathbb{E}[X])}\right] = \prod_{i=1}^{t}\mathbb{E}\left[e^{s(X_i - \mathbb{E}[X])}\right]$$

i teraz niestety trochę machania rękami…

to jest lemat Hoeffdinga, z nim jest trochę roboty…

$$\mathbb{E}\left[e^{s(X - \mathbb{E}[X])}\right] \leq e^{\frac{s^2(b-a)^2}{8}}$$

wrzucamy we wcześniejsze wzorki…

$$\mathbb{P}\left(\sum_{i=1}^{t}(X_i - \mathbb{E}[X]) \geq tu\right) \leq \frac{e^{\frac{ts^2(b-a)^2}{8}}}{e^{stu}}$$

szukamy optymalnego s jak na analizie…

$$s = \frac{4tu}{(b-a)^2}$$

I dostajemy finalnie

$$\mathbb{P}\left(\overline{X}_t - \mathbb{E}[X] \geq u\right) \leq e^{-2tu^2}$$

Selekcja w oparciu o górną granicę ufności

- w selekcji typu UCB (**Upper Confidence Bounds**) wybieramy zachłannie w oparciu o aktualną estymatę wartości danej akcji oraz górną granicę ufności powiązaną z tą estymatą

estymata na bazie średniej z t próbek

$$Q(a) \leq \hat{Q}_t(a) + \hat{U}_t(a)$$

$$a_t^{UCB} = argmax_{a \in \mathcal{A}} \hat{Q}_t(a) + \hat{U}_t(a)$$

- pozostaje więc pytanie – jak z kolei estymować tą granicę?
- skorzystamy z nierówności Hoefdinga

$$\mathbb{P}[\mathbb{E}[X] > \overline{X}_t + u] \leq e^{-2tu^2}$$

- dla naszego przypadku będzie ona wyglądać następująco

$$\mathbb{P}[Q(a) > \hat{Q}_t(a) + U_t(a)] \leq e^{-2tU_t(a)^2}$$

prawdopodobieństwo, że nasza estymata (wraz z granicą ufności) jest za niska

- chcemy, by granica „działała”, a więc prawdopodobieństwo lewej nierówności było jak najniższe; przyjmijmy, że wystarczy nam pewne małe p

$$e^{-2tU_t(a)^2} = p \qquad U_t(a) = \sqrt{\frac{-\log p}{2N_t(a)}}$$

t zostało zamienione na konkretny licznik wystąpień danej akcji: $N_t(a)$

- ile powinno wynosić p? jedną z najpopularniejszych heurez jest uznanie, że powinno maleć z czasem, np. $p = t^{-4}$
- uzyskujemy wtedy algorytm UCB1

$$A_t \doteq \underset{a}{\operatorname{argmax}} \left[Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right]$$

Selekcja w oparciu o górną granicę ufności

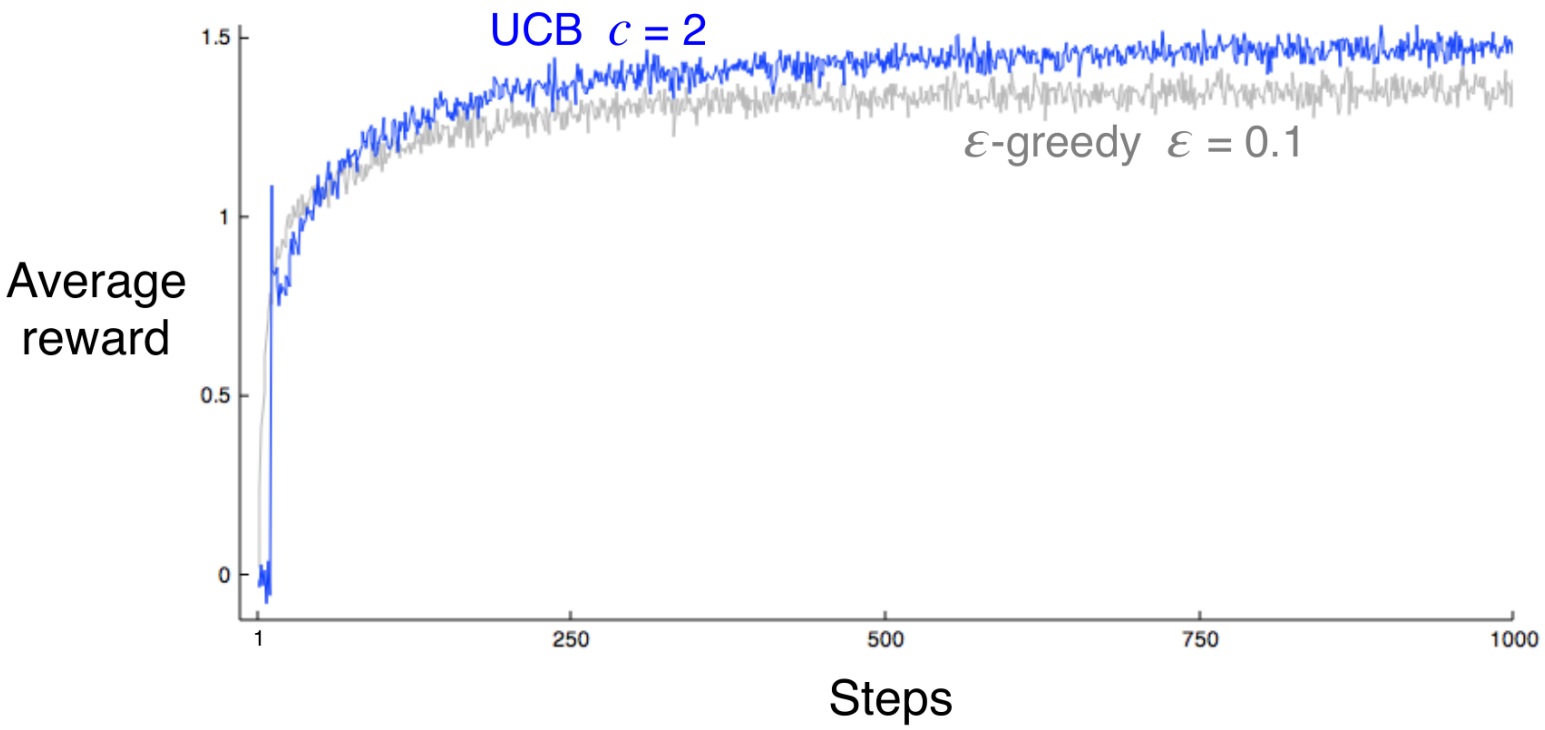

- …ale problemy z uogólnieniem podejścia dla bardziej złożonych problemów!

Podejście gradientowe

- do tej pory zakładaliśmy, iż akcję wybieramy w oparciu o funkcję wartościującą – ale to przecież nie jest jedyna możliwość!
- inną opcją jest wykorzystanie funkcji preferencji $H_t(a)$ – im większa preferencja, tym większa szansa na wybór danej akcji
- dokładne prawdopodobieństwo możemy uzyskać stosując np. selekcję *soft-max*:

$$\Pr\{A_t = a\} \doteq \frac{e^{H_t(a)}}{\sum_{b=1}^{k} e^{H_t(b)}} \doteq \pi_t(a)$$

- tak zdefiniowany problem można rozwiązać techniką stochastycznego spadku (a właściwie wspinania się) po gradiencie

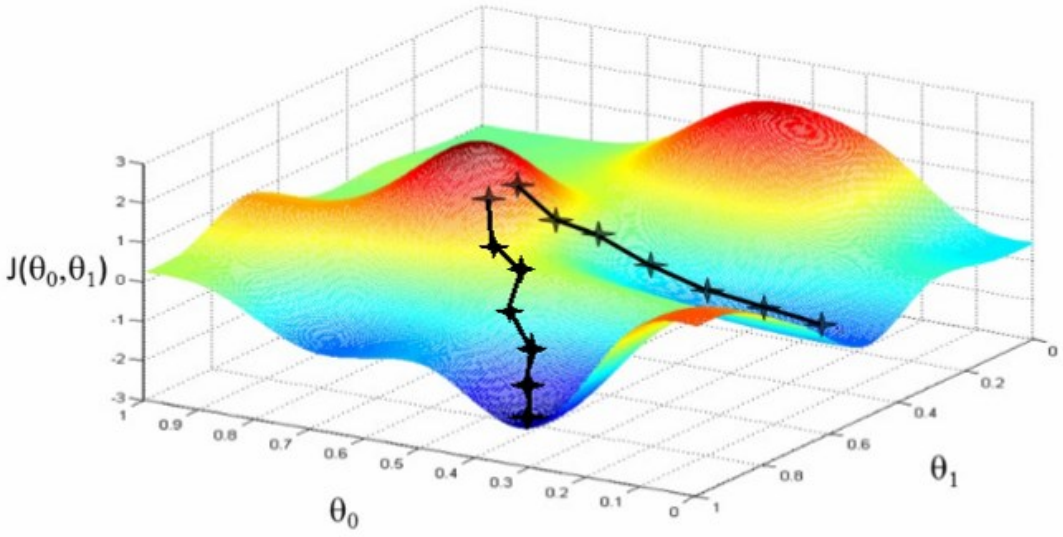

Podejście gradientowe

$$H_{t+1}(a) \doteq H_t(a) + \alpha \frac{\partial \mathbb{E}[R_t]}{\partial H_t(a)}$$

$$\mathbb{E}[R_t] = \sum_x \pi_t(x) q_*(x)$$

$$\frac{\partial \mathbb{E}[R_t]}{\partial H_t(a)} = \frac{\partial}{\partial H_t(a)} \left[\sum_x \pi_t(x) q_*(x) \right]$$

$$= \sum_x q_*(x) \frac{\partial \pi_t(x)}{\partial H_t(a)} \qquad \sum_x \frac{\partial \pi_t(x)}{\partial H_t(a)} = 0$$

$$= \sum_x \left(q_*(x) - B_t\right) \frac{\partial \pi_t(x)}{\partial H_t(a)}$$

bo suma prawdopodobieństw to zawsze 1

pod B_t mogliśmy podstawić cokolwiek – a więc również aktualną średnią

zwykła pochodna z soft-max

$$\frac{\partial \mathbb{E}[R_t]}{\partial H_t(a)} = \sum_x \pi_t(x) \left(q_*(x) - B_t\right) \frac{\partial \pi_t(x)}{\partial H_t(a)} / \pi_t(x)$$

$$= \mathbb{E}\left[\left(q_*(A_t) - B_t\right) \frac{\partial \pi_t(A_t)}{\partial H_t(a)} / \pi_t(A_t) \right]$$

$$= \mathbb{E}\left[\left(R_t - \bar{R}_t\right) \frac{\partial \pi_t(A_t)}{\partial H_t(a)} / \pi_t(A_t) \right]$$

$$\frac{\partial \pi_t(x)}{\partial H_t(a)} = \pi_t(x) \left(\mathbb{1}_{a=x} - \pi_t(a)\right)$$

$$= \mathbb{E}\left[\left(R_t - \bar{R}_t\right) \pi_t(A_t) \left(\mathbb{1}_{a=A_t} - \pi_t(a)\right) / \pi_t(A_t) \right]$$

$$= \mathbb{E}\left[\left(R_t - \bar{R}_t\right) \left(\mathbb{1}_{a=A_t} - \pi_t(a)\right) \right]$$

nie mamy dokładnej wartości gradientu, ale mamy wyrażenie, które ma odpowiednią wartość oczekiwaną – do wersji stochastycznej to wystarczy!

$$H_{t+1}(a) = H_t(a) + \alpha \left(R_t - \bar{R}_t\right) \left(\mathbb{1}_{a=A_t} - \pi_t(a)\right)$$

Dygresja: bandyci z kontekstem

- omawiane przykłady to rozwiązania problemów stacjonarnych (rozkład nagród nie zmienia się)
- w praktyce użyteczne również, jeżeli rozkład zmienia się, ale bardzo powoli
- co, jeżeli zmiany są znacznie bardziej dynamiczne?
  - nic nie wskazuje na zmianę = zmiany są w praktyce częścią rozkładu
  - coś sugeruje zmianę stanu (np. kolor lampki) = mamy do czynienia z problemem bandytów kontekstowych
  - zmiana jest skutkiem wybranej wcześniej akcji = problem staje się pełnym problemem uczenia ze wzmocnieniem

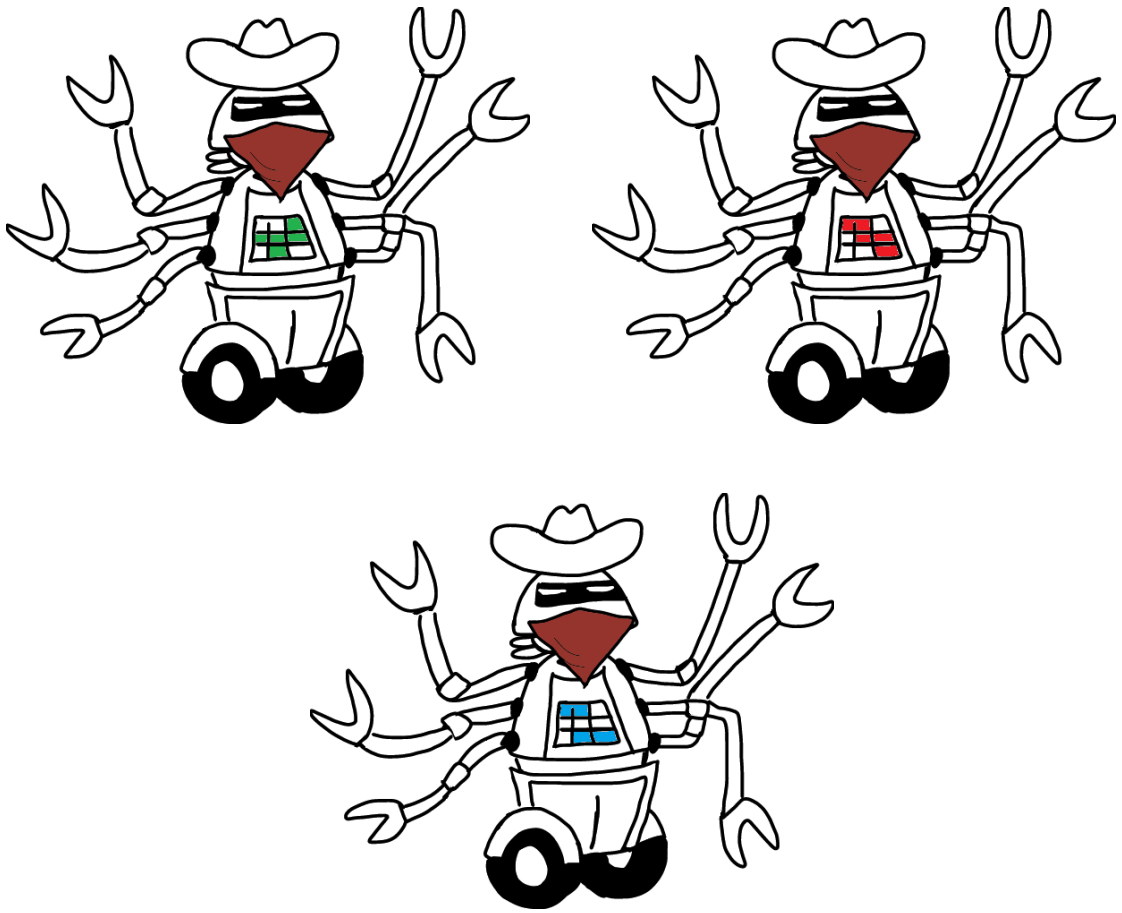

Śród-podsumowanie (czyli jak wizualizować studium parametryczne)

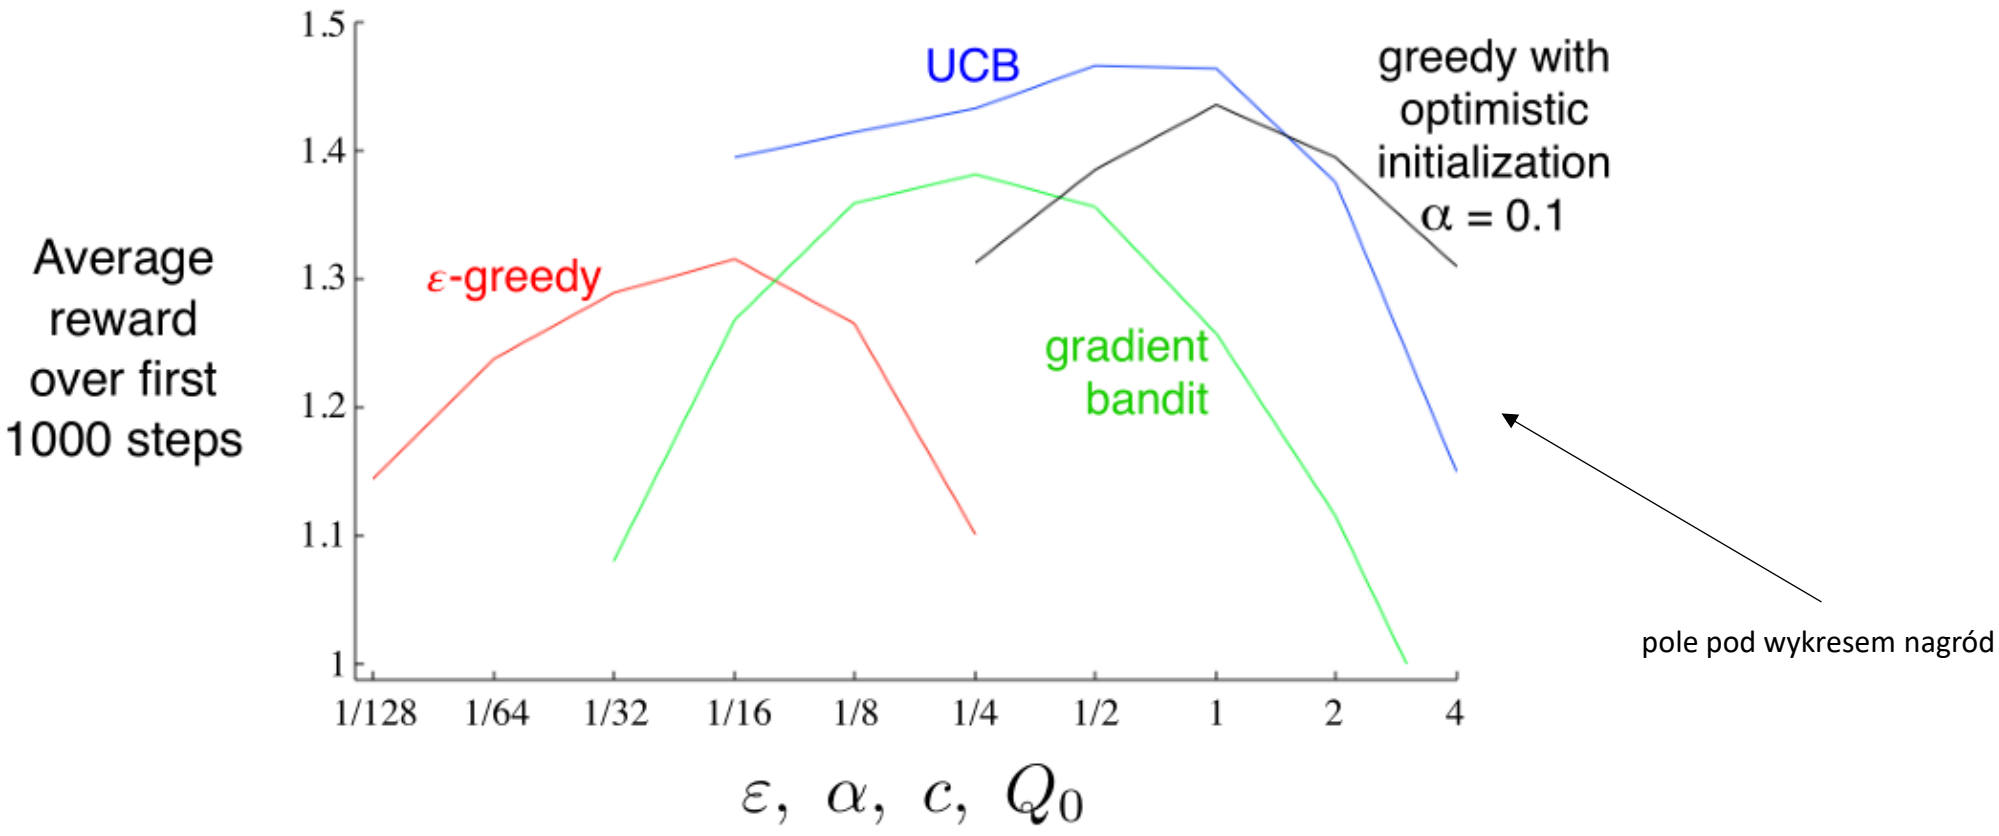

pole pod wykresem nagród